UFV

UFV.ES

# Ingeniería del dato

Guía completa sobre el preprocesamiento

00 MES

# Etapas clave del preprocesamiento de los datos

# 1. Extracción: Punto de partida

## ¿Qué es la extracción de datos?

Es el proceso de recuperar información específica de diversas fuentes, como archivos, bases de datos, páginas web o APIs. Es la base para cualquier análisis posterior.

## Fuentes Comunes de Datos

- **Archivos de Texto:** .txt, .csv, .log
- **Archivos Estructurados:** .json, .xml, .yaml
- **Bases de Datos:** SQLite, MySQL, PostgreSQL
- **Fuentes Web:** HTML, APIs REST

## Métodos de Extracción

- Manipulación de Strings
- Expresiones Regulares
- Librerías de 'Parsing'
- Consultas a Bases de Datos

# ETL vs ETL

## ETL (Extract, Transform, Load): El enfoque tradicional.

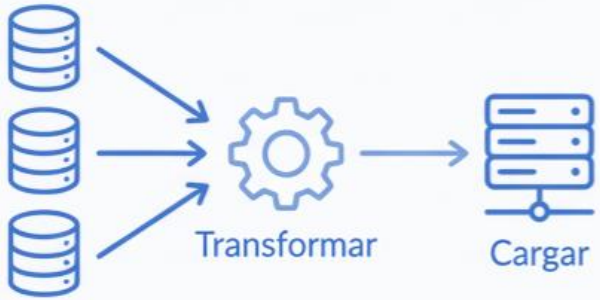


1. **Extracción:** Recopilación de datos.
2. **Transformación:** Se unifica y limpia la información antes de cargarla.
3. **Carga:** La información procesada se guarda en el destino final.

## ELT (Extract, Load, Transform): El enfoque moderno.

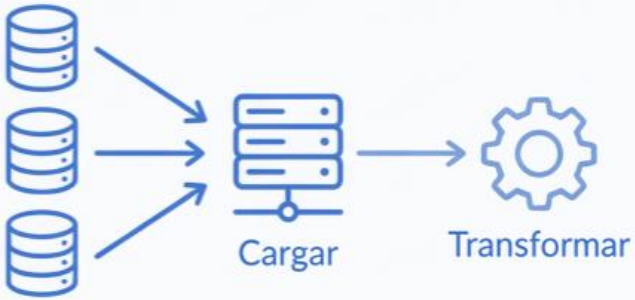


1. **Extracción:** Recopilación de datos.
2. **Carga:** Los datos brutos se cargan directamente en el destino.
3. **Transformación:** Se realiza 'in situ' utilizando la potencia del sistema de destino.

**Diferencia Clave:** ELT es ideal para grandes volúmenes de datos no estructurados y entornos cloud, siendo más rápido en la ingesta. ETL es más común en sistemas relacionales tradicionales.

# Pandas

## La Herramienta Esencial del Viaje: Pandas

**Componentes Principales**
- **Serie**: Una columna de datos, similar a un array unidimensional.
- **DataFrame**: Una tabla multidimensional compuesta por un conjunto de Series.

**Características del DataFrame**
- Las columnas pueden ser de diferentes tipos de datos.
- Tamaño mutable (se pueden añadir o eliminar filas/columnas).
- Ejes etiquetados (índices para filas y nombres para columnas).
- Permite realizar operaciones aritméticas sobre filas y columnas.

**Lectura de Datos**
Pandas simplifica enormemente la extracción desde archivos:

```
df = pd.read_csv('dataset.csv', index_col=0)
```

```
df = pd.read_json('dataset.json')
```

```
df = pd.read_sql_query("SELECT * FROM tabla", conexion_db)
```

# 2. Exploración y limpieza

1. Adquisición y Preprocesamiento
2. Exploración y Limpieza
3. Modelado y Análisis
4. Expicación y Análisis
1. Adquisición y Preprocesamiento

## ¿Qué es el Análisis Exploratorio de Datos (EDA)?

Un paso crítico previo a cualquier análisis estadístico para comprender exhaustivamente los datos y verificar el cumplimiento de los requisitos estadísticos.

## ¿Por qué realizar un EDA?

- **Organizar y entender** las variables.
- **Establecer relaciones** entre ellas.
- **Encontrar patrones ocultos** (data insights).
- **Ayudar a escoger** el modelo de análisis correcto.

## El Proceso Cíclico del EDA

# Tipos de datos

La distinción más importante es entre datos numéricos y categóricos, ya que determina el método de análisis apropiado y válido.

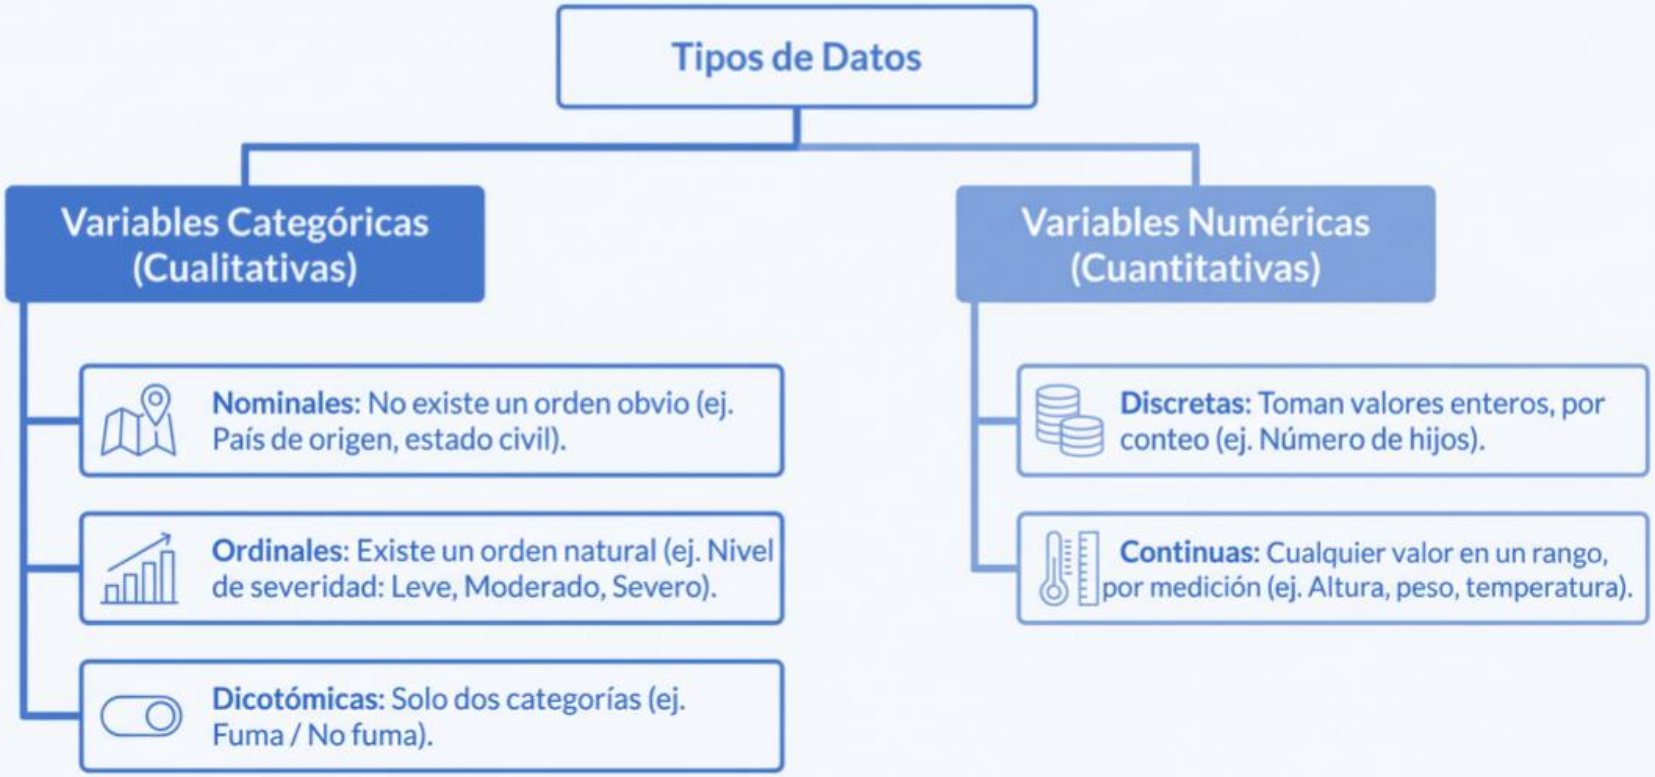

# Validación de los datos

**¿Qué es la validación de datos?**

El proceso de asegurar la consistencia y precisión dentro de un conjunto de datos. Si los datos no son precisos desde el comienzo, los resultados no serán precisos.

**Tipos de Datos:** ¿Son los datos del tipo que se indica? (ej. una columna numérica no debe tener texto).

**Rango de Variables:** ¿Están los valores dentro de un rango lógico? (ej. una nota de examen no puede ser 12 sobre 10).

**Unicidad:** ¿Existen identificadores únicos duplicados?

**Consistencia de Expresiones:** ¿Se usan los mismos formatos y nomenclaturas? (ej. 'EE.UU.' vs 'USA').

**Valores Nulos:** ¿Hay datos faltantes? ¿Por qué? ¿Están explícitos (NaN) o implícitos?

# Tratamiento de valores nulos

Errores en la recolección, problemas de transcripción, o valores no disponibles.

## Rellenar con Estadísticos Descriptivos

- **Media**: Para datos con distribución normal.
- **Mediana**: Para datos asimétricos o con outliers.
- **Moda**: Para variables categóricas.

## Rellenar por Valores Adyacentes

- **Imputación hacia adelante/atrás (ffill/bfill)**: Útil en series temporales.

## Eliminación

- **Eliminar Filas**: Viable si el porcentaje de datos faltantes es muy bajo.
- **Eliminar Columnas**: Si una variable tiene >50% de datos ausentes.

## Imputación con Machine Learning

- Usar modelos predictivos (ej. k-NN, regresión) para estimar los valores faltantes basándose en otras variables.

# Outliers

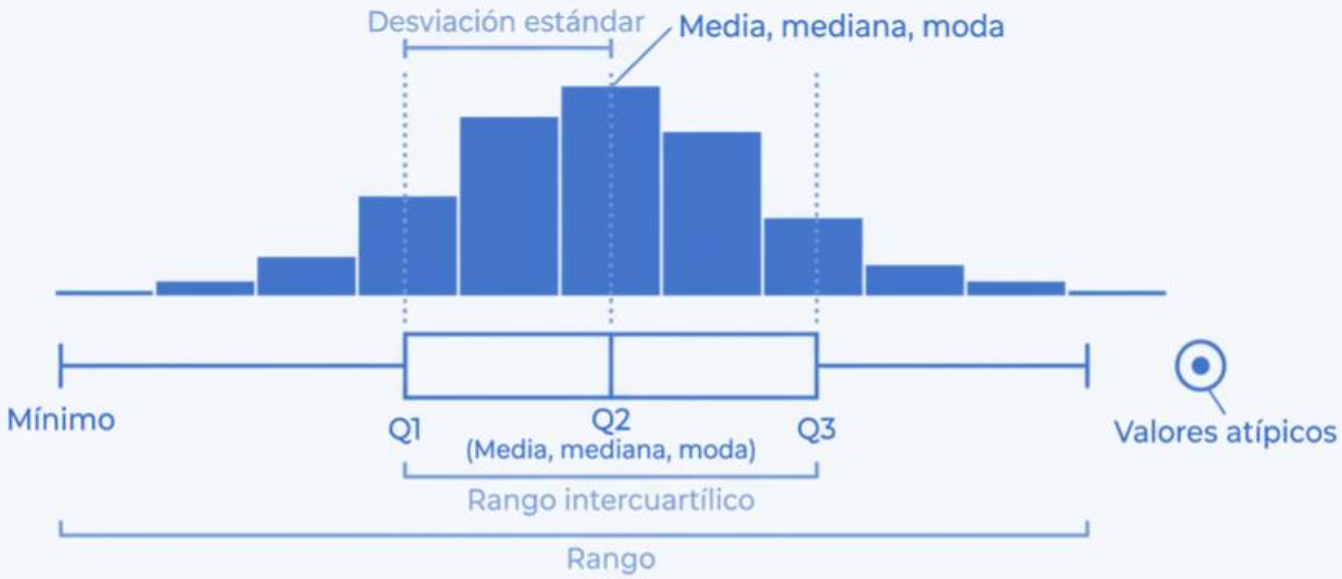


## ¿Qué es un Outlier?

Una observación que exhibe una desviación significativa respecto al patrón general. Pueden distorsionar estadísticos y comprometer modelos.

## Estrategias de Tratamiento

- **Verificar**: ¿Es un error de entrada de datos o un valor real pero extremo?
- **Métodos robustos**: Usar estadísticas menos sensibles a outliers (ej. mediana).
- **Eliminación**: Descartar el outlier con precaución, justificando la decisión.
- **Sustitución**: Reemplazar por la media/mediana (puede introducir sesgos).

# 3. Transformaciones

**NumPy: La Base del Cómputo Científico en Python**
- Significa 'Numerical Python' y es una biblioteca de código abierto.
- Proporciona soporte para matrices y arrays multidimensionales (el objeto `ndarray`).
- Es la base sobre la que se construyen librerías como Pandas.

**El `ndarray`**
- Estructura de datos eficiente y flexible.
- Homogénea: todos los elementos deben ser del mismo tipo, lo que garantiza alto rendimiento.

**Operaciones Fundamentales**
- **Creación:** `np.array()`, `np.zeros()`, `np.arange()`
- **Matemáticas:** Suma, resta, etc., de forma vectorizada.
- **Álgebra Matricial:** Producto escalar (`@`), traspuesta (`.T`).

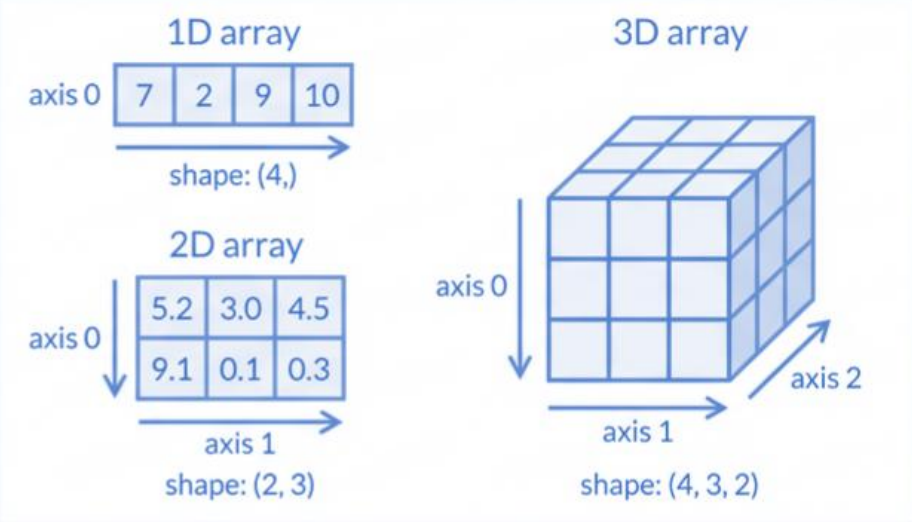


```
import numpy as np

a = np.array([[1, 2], [3, 4]])
b = np.array([[5, 6], [7, 8]])

# Producto matricial
c = a @ b
```

## 3. Transformaciones

- **¿Qué es la Correlación (r)?:** Mide la relación *lineal* entre dos variables, reflejando su fuerza y dirección.
  - **Positiva (r ≈ +1)**: Si una variable aumenta, la otra también.
  - **Negativa (r ≈ -1)**: Si una variable aumenta, la otra disminuye.
  - **Sin Correlación (r ≈ 0)**: No hay relación lineal clara.
- **Utilidad en el Análisis:**
  - **Identificación de Redundancia**: Simplifica el modelo.
  - **Guía para Modelos Predictivos**: Ayuda a seleccionar variables.
  - **Base para PCA**: Para reducir la dimensionalidad.

| | Var A | Var B | Var C | Var D | Var E |
|---|---|---|---|---|---|
| Var A | 1.00 | 0.85 | -0.72 | 0.10 | -0.45 |
| Var B | 0.85 | 1.00 | 0.10 | -0.45 | 0.60 |
| Var C | -0.72 | 0.00 | 1.00 | 0.05 | -0.90 |
| Var D | 0.60 | 0.05 | 0.05 | 1.00 | 0.30 |
| Var E | -0.15 | -0.15 | -0.90 | 0.30 | 1.00 |

# Visualizaciones

La visualización no es solo el paso final; es una herramienta clave durante todo el EDA.

## 1 Gráficos para Variables Categóricas

- **Gráfico de Barras:** Asocia una barra a cada categoría. Las barras están separadas.
- **Gráfico de Tarta (Pie Chart):** Representa la frecuencia relativa. Útil para pocas categorías.

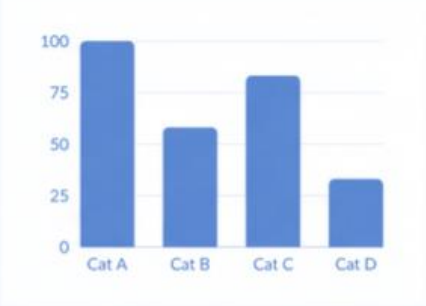


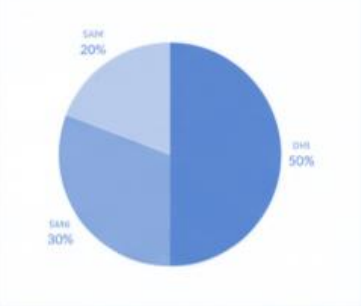


## 2 Gráficos para Variables Numéricas

- **Histograma:** Representa la distribución de frecuencias. Las barras están juntas, indicando continuidad. Permite identificar la forma de la distribución.

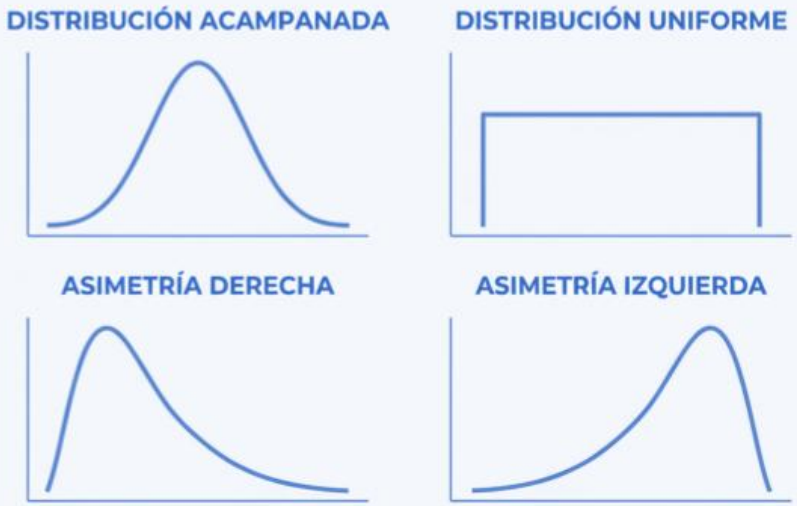

# Vistazo rápido con Pandas

Una vez cargados los datos, Pandas ofrece comandos para una visión general inmediata.

- **Section 1: Primer Vistazo**
  - **movies_df.head()**: Muestra las primeras 5 filas para una inspección visual.
  - **movies_df.tail()**: Muestra las últimas 5 filas.

- **Section 2: Información Estructural**
  - **movies_df.shape**: Devuelve una tupla con (número de filas, número de columnas).
  - **movies_df.info()**: Proporciona un resumen técnico esencial: número de entradas, columnas, tipos de datos, valores no nulos y uso de memoria.

OUT:

```
<class 'pandas.core.frame.DataFrame'>
Index: 1000 entries, Guardians of the Galaxy to Nine Lives
Data columns (total 11 columns):
Rank                  1000 non-null int64
Genre                 1000 non-null object
Description           1000 non-null object
Director              1000 non-null object
Actors                1000 non-null object
Year                  1000 non-null int64
Runtime (Minutes)     1000 non-null int64
Rating                1000 non-null float64
Votes                 1000 non-null int64
Revenue (Millions)    872 non-null float64
Metascore             936 non-null float64
dtypes: float64(3), int64(4), object(4)
memory usage: 97.6+ KB
```

- **Section 3: Resumen Estadístico**
  - **movies_df.describe()**: Genera estadísticas descriptivas para las columnas numéricas y categóricas.

OUT:

| | rank | year | runtime | rating | |
|---|---|---|---|---|---|
| count | 1000.000000 | 1000.000000 | 1000.000000 | 1000.000000 | 1.0 |
| mean | 500.500000 | 2012.783000 | 113.17000 | 6.723200 | 1.8 |
| std | 288.819456 | 3.205962 | 18.810908 | 0.945429 | 1.8 |
| min | 1.000000 | 2006.000000 | 68.000000 | 1.900000 | 6.1 |
| 29% | 250.750000 | 2010.000000 | 100.000000 | 6.200000 | 3.6 |
| 50% | 500.500000 | 2014.000000 | 111.000000 | 6.800000 | 1.1 |
| 75% | 750.250000 | 2016.000000 | 123.000000 | 7.400000 | 2.3 |
| max | 1000.000000 | 2016.000000 | 191.000000 | 9.000000 | 1.7 |

OUT:

```
count                        1000
unique                        207
top       Action, Adventure, Sci-Fi
freq                           50
Name: genre, dtype: object
```

# Vistazo rápido con Pandas

El viaje del dato transforma el potencial caótico de la información cruda en conocimiento estructurado y accionable.

Hemos recorrido el itinerario completo:

1. **Recolectamos** los datos de diversas fuentes.
2. **Limpiamos** y validamos para asegurar su calidad.
3. **Identificamos patrones** y relaciones a través del análisis exploratorio.
4. **Seleccionamos visualizaciones** para comunicar los hallazgos.
5. **Construimos una historia** que guía a la audiencia.

Un dato limpio, validado y bien comprendido es el cimiento sobre el cual se construyen modelos precisos, decisiones inteligentes y narrativas de datos convincentes.

# Rúbrica Ingeniería del Dato

| Rubrica Ingeniería del dato | | | | | |
|---|---|---|---|---|---|
| | 0-2 | 2-4 | 4-6 | 6-8 | 8-10 |
| Origen de los datos | Datos obtenidos de repositorios compartidos. | Datos obtenidos de repositorios compartidos en los que se lleva a cabo limpieza. | Datos obtenidos de fuentes oficiales o repositorios establecidos a los que se les realizan transformaciones y limpieza. | Combinación de diferentes repositorios, con proceso de limpieza de los datos. | Combinación de diferentes repositorios y/o elaboración manual del set de datos. Transformaciones y limpieza completas. |
| Limpieza y transformación | No existe proceso de limpieza y/o transformación | Limpieza de los datos, eliminación de nulos… | Transformaciones básicas de formato en los datos, eliminación de columnas y/o vbles. Visualización antes y después transformaciones | Limpieza y transformación, eliminación de nulos y transformaciones de formato. Explicación completa del proceso de eliminación de variables. Visualización antes y después transformaciones | Limpieza y transformación de los datos mediante técnicas de interpolación para evitar valores nulos, aumento de datos, cambio de valores. Explicación completa del proceso de eliminación de variables. |
| Análisis exploratorio | Enumeración de variables | Descripción de las variables con temporalidad, periodo, formato y visualización de las mismas. | Estudio estadístico básico sin contexto, con estadísticos básicos de las variables. | Estudio estadístico completo y adecuado. Estudio descriptivo | Estudio estadísticos y descriptivo completos con gráficos, visualizaciones adecuadas, estudio ST en su caso, justificación del tipo de análisis descriptivo. |

UFV

91 351 03 03
INFO@UFV.ES
UFV.ES

CTRA. POZUELO-MAJADAHONDA
KM 1.800, 28223 POZUELO DE ALARCÓN
MADRID. ES